Audio Harness — итоговый план MVP

Oct 21, 2026 · @Алексей Фёдоров

Цель MVP и инструменты

MVP — агент, который по запросу на естественном языке чистит запись, выделяет голос, анализирует тональность и темп, добавляет бас и барабаны в MIDI и отдаёт проект в REAPER, с подтверждением и откатом каждого шага. Каждая метрика считается на открытых размеченных данных или синтетике с известным ответом, поэтому собственная разметка для MVP не нужна.

Инструмент	Что делает	Технология	Метрика	Данные для оценки
`denoise`	Очистка записи от шума	DeepFilterNet (48 кГц)	ΔSI-SDR, дБ; DNSMOS	Чистый вокал + добавленный шум
`separate`	Стемы и выделение голоса	Demucs `htdemucs`	SI-SDR вокала, дБ	Свои миксы: вокал + минус
`analyze`	Биты, темп, тональность, аккорды	Beat This! (биты, темп), madmom (аккорды, тональность)	Beat F-measure; BPM Acc1/Acc2; key MIREX; chord overlap `majmin`	FSL10K (эксперты), GuitarSet
`generate_accompaniment`	Бас и барабаны в MIDI по аккордам	Шаблоны + Groove MIDI Dataset	Доля нот аккорда на сильных долях, %; отклонение от сетки, мс	Автоматически на любом входе
`render`	MIDI в аудио + lo-fi обработка	pretty_midi + FluidSynth, pedalboard	—	—
`export`	Стемы + MIDI + проект REAPER	pretty_midi, генерация `.rpp`	Открывается в REAPER: да/нет	—

Инструмент	Что делает	Технология	Метрика	Данные для оценки
Агент	План, подтверждение, выполнение, откат	LLM с tool use + Pydantic-схемы	Task success rate, %; точность плана, %; латентность, с	20–30 сценариев с эталонными планами

Вне MVP: MiniMax и MusicGen, микс и ремастер, CLAP и FAD, своя разметка аккордов, user study, живая связь с DAW.

Что установить

Каждый тяжёлый инструмент живёт в своём окружении uv, чтобы madmom, DeepFilterNet и Demucs не конфликтовали по версиям torch и numpy. Всё работает на CPU; GPU не обязателен.

Системные пакеты (macOS, Homebrew)

Пакет	Зачем
`uv`	Окружения и запуск инструментов
`ffmpeg`	Чтение mp3/m4a, конвертация
`fluid-synth`	Рендер MIDI в аудио
`git`, `git-lfs`	Код и крупные файлы
REAPER	Проверка экспорта `.rpp` (бесплатный пробный период)
Sonic Visualiser	Просмотр битов и аккордов, отладка анализа

Python-окружения по инструментам

Окружение	Пакеты	Оговорки
`tools/denoise`	`deepfilternet`, `torch`, `torchaudio`, `soxr`, `soundfile`	Только 48 кГц. Проект давно не обновлялся: зафиксировать версии torch, при которых он работает
`tools/separate`	`demucs` (4.1.0, форк adefossez), `soundfile`	Оригинальный репозиторий Meta архивирован, ставить с PyPI
`tools/analyze`	`beat-this`, `madmom` из git, `soxr`	madmom с PyPI не ставится на Python ⩾ 3.10; модели madmom под CC BY-NC-SA
`tools/generate`	`pretty_midi`, `mido`, `numpy`	Groove MIDI скачать отдельно
`tools/render`	`pretty_midi`, `pyfluidsynth`, `pedalboard`, `pyloudnorm`	pedalboard, насколько известно, под GPLv3 — проверить
`tools/export`	`pretty_midi`, `rpp`	—
`orchestrator`	LLM SDK, `pydantic`, `gradio`, `sqlalchemy` или `sqlite3`	Агент, хранилище артефактов, UI
`eval`	`mir_eval`, `mirdata`, `torchmetrics` (SI-SDR), DNSMOS	Скрипты метрик

Модели и ресурсы

- Веса DeepFilterNet (~50 МБ, скачиваются при первом запуске).
- Веса Demucs `htdemucs` (скачиваются при первом запуске).
- Чекпоинт Beat This! `final0`.
- GM-саундфонт, например GeneralUser GS.
- API-ключ LLM с поддержкой tool use.
- [ ] Первый день: поставить `tools/analyze` (madmom из git) и `tools/denoise` на всех машинах команды — здесь выше всего риск застрять.

Датасеты

Для MVP нужно семь наборов: три публичных, два синтетических (собираются скриптом за 1–2 дня), сценарии для агента и демо-записи. Ручная разметка аккордов не нужна.

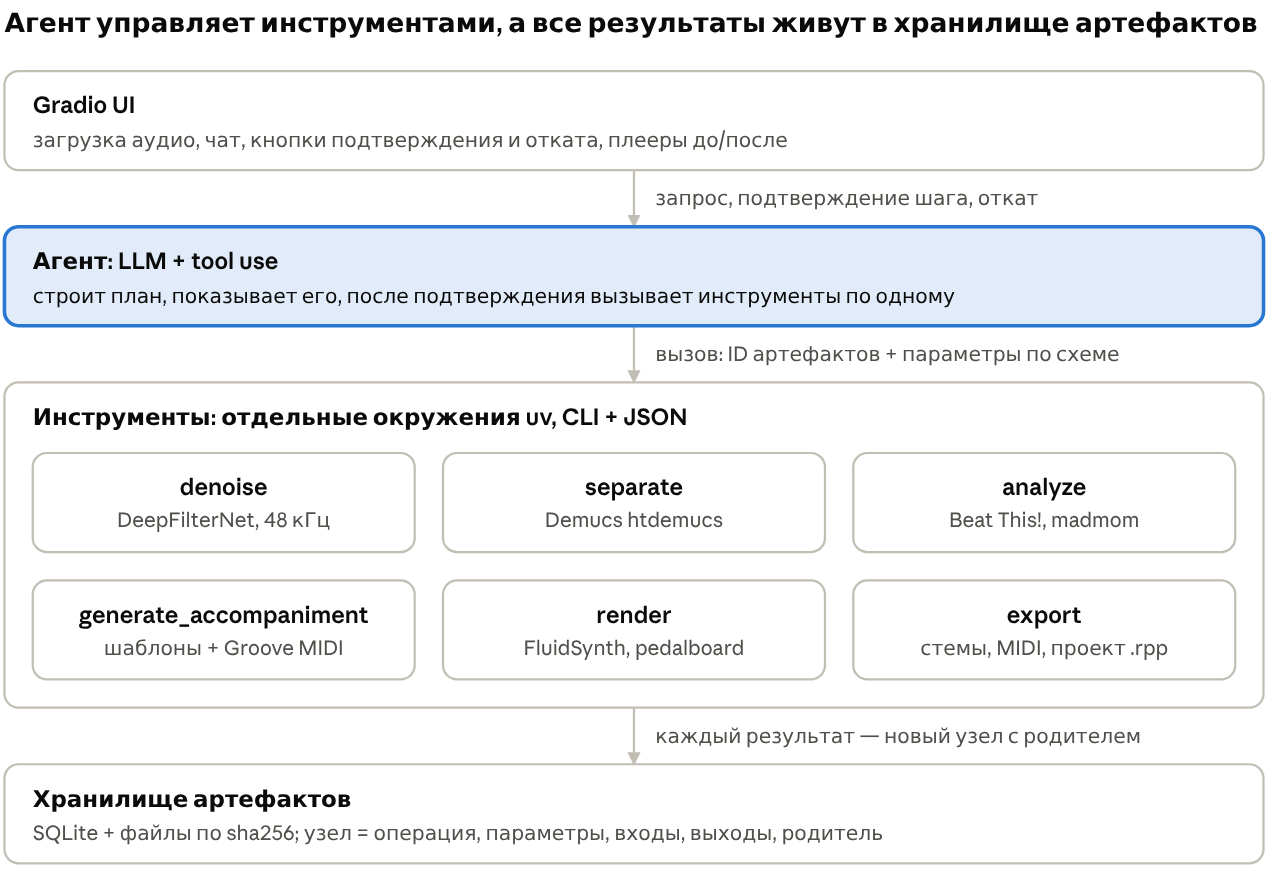
Набор	Для чего	Откуда	Объём для MVP	Лицензия
Freesound Loop Dataset (FSL10K)	BPM и тональность	Zenodo или зеркало на HF (`nicolaus625/cmi`)	Экспертно размеченная часть, гитара и клавиши, 60–100 BPM	CC, по файлу в `metadata.json`
GuitarSet	Биты, сильные доли, аккорды	Через `mirdata`	Весь набор	CC BY 4.0
Groove MIDI Dataset	Паттерны барабанов для генерации	Сайт Magenta или TFDS	Отбор по стилю и темпу	CC BY 4.0
Синтетика для `denoise`	ΔSI-SDR, DNSMOS	Чистый вокал или речь + шум (кондиционер, улица, гул) на SNR 0, 5, 10 дБ	50–100 пар	Зависит от исходников, брать CC0/CC BY
Синтетика для `separate`	SI-SDR вокала	Чистый вокал + инструментальный минус	30–50 миксов	То же
Сценарии для агента	Task success, точность плана	Пишет команда; формулировки спросить у 5–10 продюсеров	5–10 типов × 3–5 входов = 20–50 прогонов	Свои
Демо-записи	Только презентация	Свои: вокал и гитара на телефон, 15–30 с	3–5 записей	Свои

Правила:

- Тестовая часть замораживается до подбора порогов и не трогается при разработке.
- Разбиение dev/test по источнику или автору, а не случайно.

- Данные в git-lfs или DVC, у каждого файла записаны источник и лицензия.
- Для шумоподавления лучше брать речь и пение отдельно: DeepFilterNet обучен на речи, на пении результат может быть хуже, и это стоит показать честно.
- `vikhyatk/lofi`, `lofiHipHop` и MusicBench для оценки не годятся: нет разметки или она получена моделями.

Архитектура и репозиторий



архитектура MVP · 4 слоя, 6 инструментов

Агент передаёт инструментам только ID артефактов, а не аудио; откат — это перемещение указателя на предыдущий узел, перегенерация — новая ветка от того же родителя. Для клипов 15–30 с очередь задач не нужна: вызовы синхронные.

Контракт инструмента: на вход путь к файлу и JSON с параметрами, на выход JSON с путями результатов и метаданными. Канонический формат всех артефактов — WAV 44.1 кГц, стерео, float32; ресемплинг только в одном модуле на `soxr`.

```
audio-harness/
  tools/
    denoise/      pyproject.toml
    separate/     pyproject.toml
    analyze/      pyproject.toml
    generate/     pyproject.toml
    render/       pyproject.toml
    export/       pyproject.toml
  orchestrator/   агент, схемы инструментов, хранилище, Gradio
  eval/           скрипты метрик, по одному на инструмент
  data/           датасеты (git-lfs или DVC)
  scenarios/      сценарии и эталонные планы для агента
  demo/           демо-записи и заранее прогнанные результаты
```

Этапы работ

Начинать с каркаса: хранилище артефактов, единый контракт инструментов и один инструмент сквозняком через UI без агента. Агент добавляется последним, поверх уже работающих инструментов.

1. **Каркас** — хранилище артефактов (SQLite + файлы по sha256), контракт CLI, Gradio-страница, `separate` от загрузки до прослушивания.
   - Готово, когда: загруженный файл разделяется на стемы, у каждого результата есть узел с родителем, откат на предыдущий узел работает.
2. **Анализ и очистка** — `analyze` и `denoise` по тому же контракту, ресемплинг в одном месте.
   - Готово, когда: на демо-записи выдаются BPM, тональность, сетка битов, аккорды; шумоподавление слышно до/после.
   - Параллельно: скрипты метрик на FSL10K и GuitarSet, первая таблица цифр.
3. **Генерация и экспорт** — `generate_accompaniment`, `render`, `export` в `.rpp`.
   - Готово, когда: проект открывается в REAPER, бас и барабаны совпадают с сеткой и аккордами, quality gates (доля нот аккорда, отклонение от сетки) считаются автоматически.

4. **Агент** — план в JSON по Pydantic-схемам, показ плана, подтверждение, выполнение, откат и перегенерация шага из UI.
   - Готово, когда: 20+ сценариев прогоняются скриптом, посчитаны task success и точность плана.
5. **Метрики и презентация** — синтетика для `denoise` и `separate`, итоговая таблица, спектрограммы до/после, дерево версий, заранее прогнанные демо.
   - Готово, когда: каждая цифра на слайде пересчитывается одной командой.

Первые задачи:

- [ ] Поставить `tools/analyze` и `tools/denoise` на всех машинах
- [ ] Описать контракт CLI и формат JSON-ответа инструмента
- [ ] Поднять хранилище артефактов и Gradio-страницу с `separate`
- [ ] Скачать GuitarSet через `mirdata` и FSL10K
- [ ] Записать 3–5 демо-записей
- [ ] Распределить роли: каркас и агент, анализ и метрики, генерация и экспорт, данные и демо

Риски и страховки

Главные риски — установка зависимостей и качество распознавания аккордов на lo-fi гитаре; оба проверяются в первую неделю.

Риск	Признак	Что делать
madmom или DeepFilterNet не ставятся	Ошибки сборки, конфликт torch	Отдельные окружения uv; при провале — Docker-образ с закреплённым Python
Аккорды на гитаре с эффектами распознаются плохо	Chord overlap на демо-записях заметно ниже, чем на GuitarSet	Ручное подтверждение и правка аккордов в UI как штатный шаг copilot
DeepFilterNet портит пение	Пропадают тянутые ноты и вибрато	Для вокала в миксе — Demucs или BS-RoFormer через `audio-separator`, DeepFilterNet — для речи

Риск	Признак	Что делать
Обработка на сцене идёт слишком долго	Больше 30 с на шаг	Клипы 15–30 с; заранее прогнанные результаты как запасной вариант
LLM строит неверный план	Неверный порядок или аргументы	Строгие схемы, валидация с возвратом ошибки модели, до 3 ретраев, затем вопрос пользователю
Лицензии	madmom (NC), pedalboard (GPL), веса моделей	Для учебного MVP допустимо; в презентации указать и назвать замены для продукта
Расхождение частот дискретизации	Сдвиг битов, ошибка DeepFilterNet	Канонический формат 44.1 кГц, ресемплинг только в одном месте